BÁO CÁO PHÂN TÍCH GAME COOKIE CATS

CHƯƠNG 1. GIỚI THIỆU CHUNG VỀ DỰ ÁN PHÂN TÍCH

I. Mô tả về bộ dữ liệu

1.1. Mô tả bộ dữ liệu

Bộ dữ liệu ghi lại kết quả của một thử nghiệm A/B trong trò chơi di động **Cookie Cats**. Thử nghiệm nhằm đánh giá tác động của việc chuyển cổng đầu tiên trong trò chơi từ level 30 sang level 40. Khi cài đặt trò chơi, mỗi người chơi được phân ngẫu nhiên vào một trong hai nhóm: gate_30 (cổng ở level 30) hoặc gate_40 (cổng ở level 40).

Bộ dữ liệu gồm 90.189 người chơi và năm biến:

Biến	**Mô tả**
userid	Mã định danh duy nhất của người chơi.
version	Nhóm thử nghiệm mà người chơi được phân vào: gate_30 hoặc gate_40.
sum_gamerounds	Tổng số vòng chơi của người chơi trong 14 ngày đầu sau khi cài đặt.
retention_1	Cho biết người chơi có quay lại chơi vào ngày thứ nhất sau khi cài đặt hay không.
retention_7	Cho biết người chơi có quay lại chơi vào ngày thứ bảy sau khi cài đặt hay không.

Do người chơi được phân ngẫu nhiên vào hai nhóm, dữ liệu có thể được dùng để so sánh hành vi chơi và tỷ lệ quay lại giữa vị trí cổng level 30 và level 40.

II. Mục tiêu nghiên cứu và giả thuyết

- Chỉ số chính: retention ngày 7 (retention_7).
- Chỉ số phụ: retention ngày 1 (retention_1) và số game rounds trong 14 ngày đầu (sum_gamerounds).
- Với retention ngày 7:

- H_0: tỷ lệ retention của gate_30 bằng gate_40.
- H_1: hai tỷ lệ khác nhau.

- Cùng cấu trúc giả thuyết hai phía được áp dụng cho retention ngày 1. Với game rounds, phân phối số vòng chơi giữa hai nhóm được so sánh bằng kiểm định phi tham số.

CHƯƠNG 2. DỮ LIỆU VÀ PHƯƠNG PHÁP

I. Nguồn dữ liệu

Bộ dữ liệu có 90.189 người chơi và năm trường: userid, version, sum_gamerounds, retention_1 và retention_7. Mỗi userid là một người chơi; version xác định nhóm thử nghiệm. Nguồn dữ liệu là bộ Mobile Games A/B Testing Cookie Cats trên Kaggle.

II. Loại dữ liệu

Biến	**Mô tả**
userid	số nguyên (int64), dùng làm mã định danh người chơi.
version	dạng văn bản (object), ghi nhóm gate_30 hoặc gate_40.
sum_gamerounds	số nguyên (int64), biểu thị số vòng chơi.
retention_1	kiểu Boolean (bool), nhận giá trị True hoặc False.
retention_7	kiểu Boolean (bool), nhận giá trị True hoặc False.

III. Đánh giá chất lượng dữ liệu

Để đánh giá chất lượng dữ liệu này tôi sẽ dựa theo tiêu chí ISO 8000 để đánh giá

ISO 8000 là tiêu chuẩn quốc tế về chất lượng dữ liệu, bao gồm các tiêu chí quan trọng để đảm bảo dữ liệu có thể sử dụng hiệu quả trong thực tế.

- Syntactic Accuracy (Độ chính xác cú pháp)
- Khi nhập dữ liệu CSV vào Excel, các giá trị ban đầu bị gộp vào một cột do thiết lập dấu phân tách chưa phù hợp. Đây là vấn đề về định dạng/cú pháp khi đọc dữ liệu, không làm thay đổi ý nghĩa của các biến. Dữ liệu được tách lại theo dấu phẩy để mỗi trường được hiển thị đúng cột trước khi phân tích.
- Biến sum_gamerounds có một giá trị ngoại lệ đáng chú ý: một người chơi thuộc nhóm gate_30 có 49.854 vòng chơi, trong khi giá trị cao tiếp theo là 2.961. Đây là giá trị bất thường cần được kiểm tra thêm.
- Syntactic Accuracy (Độ chính xác cú pháp)

- Tính chính xác về ngữ nghĩa của dữ liệu đề cập đến việc dữ liệu phản ánh đúng thực tế và không bị sai lệch về nội dung.

- Integrity (Tính toàn vẹn dữ liệu)

- Tính toàn vẹn về cấu trúc dữ liệu
  - ❖ Qua đối chiếu và kiểm tra dữ liệu này không bị thiếu dữ liệu nào, duy nhất chỉ có một lỗi đã đề cập ở trên do đó cần làm sạch để quá trình phân tích được diễn ra thuận lợi.
- Tính toàn vẹn về nguồn gốc dữ liệu:
  - ❖ Dữ liệu được lấy từ Kaggle - một nền tảng cung cấp dữ liệu mở, được sử dụng rộng rãi trong nghiên cứu và phân tích.

- Tính tái sử dụng của dữ liệu

- Bộ dữ liệu có cấu trúc bảng và các biến được mô tả rõ ràng, gồm mã người chơi, nhóm thử nghiệm, số vòng chơi và trạng thái quay lại vào ngày thứ nhất và ngày thứ bảy.
- Dữ liệu có thể được tái sử dụng để phân tích hành vi người chơi, so sánh kết quả giữa hai nhóm và thực hiện các kiểm định A/B khác.
- Tuy nhiên, phạm vi tái sử dụng bị giới hạn ở các câu hỏi liên quan đến những biến hiện có; bộ dữ liệu không bao gồm thông tin về doanh thu, giao dịch mua hàng hoặc level thực tế người chơi đã đạt.

IV. Phương pháp

Bước	Cách thực hiện
Kiểm tra dữ liệu	Không phát hiện giá trị thiếu hoặc userid trùng trong bản dữ liệu đã tách cột.
Xử lý ngoại lệ	Loại một người chơi có số game rounds cao nhất (49.854) theo quy tắc trong notebook; còn 90.188 người chơi.
Retention	Kiểm định Chi-square cho bảng chéo nhóm thử nghiệm × kết quả True/False.
Game rounds	Kiểm định Mann-Whitney U hai phía vì số vòng chơi lệch và có đuôi dài.

Bước	Cách thực hiện
Ngưỡng	Mức ý nghĩa $\alpha = 0,05$; $p < 0,05$ được xem là có bằng chứng thống kê về khác biệt.

Các giá trị trung bình của biến True/False được diễn giải thành tỷ lệ retention. Chỉ số chính được xác định là retention ngày 7; hai chỉ số còn lại là kết quả phụ.

CHƯƠNG 3. KẾT QUẢ PHÂN TÍCH VÀ DIỄN GIẢI

I. Kết quả

Chỉ số	gate_30	gate_40	Phương pháp	p-value
Retention ngày 7	19,02%	18,20%	Chi-square	0,0016
Retention ngày 1	44,82%	44,23%	Chi-square	0,0750
Game rounds	Mean 51,34 Median 17	Mean 51,30 Median 16	Mann–Whitney U	0,0509

II. Diễn giải

Kết quả cho thấy nhóm gate_30 có retention ngày 7 là 19,02%, cao hơn nhóm gate_40 (18,20%). Chênh lệch là 0,82 điểm phần trăm. Kiểm định Chi-square cho p-value 0,0016, thấp hơn mức ý nghĩa 0,05. Vì vậy, kết quả cho thấy retention ngày 7 khác biệt có ý nghĩa thống kê giữa hai nhóm, với tỷ lệ cao hơn ở nhóm gate_30.

Retention ngày 1 cũng cao hơn ở nhóm gate_30 (44,82%) so với nhóm gate_40 (44,23%), chênh lệch 0,59 điểm phần trăm. Tuy nhiên, p-value 0,0750 lớn hơn 0,05, nên chưa đủ bằng chứng để kết luận retention ngày 1 khác biệt có ý nghĩa thống kê giữa hai nhóm.

Về số vòng chơi, trung bình của hai nhóm gần như tương đương: 51,34 vòng ở gate_30 và 51,30 vòng ở gate_40. Trung vị lần lượt là 17 và 16. Kiểm định Mann–Whitney U cho p-value 0,0509, nhỉnh hơn 0,05; do đó, chưa đủ bằng chứng để kết luận số vòng chơi khác biệt có ý nghĩa thống kê giữa hai nhóm.

Nhìn chung, trong các chỉ số được phân tích, chỉ retention ngày 7 cho thấy sự khác biệt có ý nghĩa thống kê. Kết quả quan sát được nghiêng về nhóm gate_30, trong khi retention ngày 1 và game rounds chưa cho thấy đủ bằng chứng về sự khác biệt ở mức ý nghĩa 5%.

CHƯƠNG 4. KẾT LUẬN VÀ ĐỀ XUẤT

Kết quả phân tích cho thấy nhóm gate_30 có tỷ lệ retention ngày 7 cao hơn nhóm gate_40 (19,02% so với 18,20%). Chênh lệch này có ý nghĩa thống kê ở mức 5% (p = 0,0016), cho thấy dữ liệu cung cấp bằng chứng về sự khác biệt giữa hai nhóm đối với chỉ số retention ngày 7. Vì đây là chỉ số chính của thử nghiệm, kết quả ủng hộ việc giữ cổng ở level 30 nếu mục tiêu sản phẩm là cải thiện khả năng người chơi quay lại sau một tuần.

Với retention ngày 1, nhóm gate_30 cũng có tỷ lệ cao hơn nhóm gate_40 (44,82% so với 44,23%). Tuy nhiên, kết quả kiểm định chưa đạt ý nghĩa thống kê ở mức 5% (p = 0,0750), nên chưa đủ bằng chứng để kết luận vị trí cổng tạo ra khác biệt về retention ngày 1. Tương tự, số game rounds trung bình giữa hai nhóm gần như bằng nhau; kiểm định Mann–Whitney U cho p = 0,0509, nên phân tích này chưa đủ cơ sở để khẳng định hai nhóm khác nhau về lượng chơi.

Do đó, kết luận chính của dự án là việc chuyển cổng từ level 30 lên level 40 không cho thấy cải thiện retention ngày 7 trong thử nghiệm này. Nếu doanh nghiệp ưu tiên chỉ số đó, có thể cân nhắc giữ cổng tại level 30. Tuy nhiên, quyết định triển khai không nên chỉ dựa trên retention mà cần xem xét thêm các mục tiêu kinh doanh và trải nghiệm tổng thể.

Trước khi triển khai rộng, nên phân tích thêm doanh thu, tỷ lệ mua hàng tại cổng, thời gian chơi dài hạn và phản hồi của người chơi. Những dữ liệu này giúp xác định liệu retention cao hơn có đi kèm giá trị kinh doanh tốt hơn hay không. Ngoài ra, nên kiểm tra độ nhạy của kết quả khi giữ lại người chơi có số game rounds bất thường trong kiểm định retention, đồng thời chỉ loại bản ghi đó khỏi phân tích game rounds. Điều này giúp bảo đảm cách xử lý ngoại lệ phù hợp với từng chỉ số và kết luận đáng tin cậy hơn.

CHƯƠNG 5. GIỚI HẠN VÀ BƯỚC TIẾP THEO

- Bản ghi 49.854 rounds bị loại khỏi toàn bộ df trong notebook. Vì retention của người chơi này vẫn là quan sát hợp lệ, nên chạy thêm phân tích độ nhạy: giữ người chơi trong kiểm định retention, chỉ loại khỏi phân tích game rounds.
- Notebook có đầu ra group size không nhất quán giữa các cell: dữ liệu gốc có 44.700 gate_30 và 45.489 gate_40; sau khi loại một người chơi, còn 44.699 và 45.489. Nên Restart Kernel và Run All trước khi chốt bản nộp.
- Các kiểm định phụ là khám phá; báo cáo p-value riêng mà chưa hiệu chỉnh cho nhiều phép kiểm định. Nên ưu tiên kết luận đã xác định trước cho retention ngày 7.
- Dataset không có doanh thu, cấp độ thực sự đã đạt, hay hành vi mua hàng; số rounds không tương đương số level đã hoàn thành.